

配置文件说明

配置文件位于 `configs/` 目录，使用 YAML 格式。运行命令时通过 `-c` 指定：

```
uv run python -m data_agent_baseline run-task -c configs/easy.yaml
```

一、dataset — 数据集路径

参数	类型	默认值	说明
<code>root_path</code>	路径	<code>data/public/input</code>	公开数据集的根目录，任务数据从此目录下按 <code>task_id</code> 查找

二、agent — 主 Agent 配置

参数	类型	默认值	说明
<code>model</code>	字符串	<code>gpt-4.1-mini</code>	模型名称。如果同时设置了 <code>model_env</code> ，则从环境变量读取，忽略此值
<code>model_env</code>	字符串	无	从环境变量读取模型名的变量名（仅 docker.yaml 使用）
<code>api_base</code>	URL	<code>https://api.openai.com/v1</code>	API 地址
<code>api_base_env</code>	字符串	无	从环境变量读取 API 地址的变量名（仅 docker.yaml 使用）
<code>api_key</code>	字符串	空	API Key。留空则从 <code>api_key_env</code> 指定的环境变量读取
<code>api_key_env</code>	字符串	无	环境变量名。程序会先读环境变量，读不到再读 <code>.env</code> 文件
<code>max_steps</code>	整数	16	主 Agent 最大 ReAct 轮数（model_step -> tool_step 循环次数）
<code>temperature</code>	浮点	0.0	模型温度，0 表示确定性输出

参数	类型	默认值	说明
<code>enable_data_inspector</code>	布尔	<code>false</code>	总开关 。必须设为 <code>true</code> ，下面的 <code>data_inspector</code> 配置才会生效
<code>model_request_timeout_seconds</code>	浮点	120	单次模型请求超时秒数

三、`data_inspector` — 数据探查配置

3.1 节点开关

参数	类型	默认值	说明
<code>enable_global_exploration_llm</code>	布尔	<code>true</code>	<code>true</code> ：让 LLM 把数据目录整理成易读的 markdown profile。 <code>false</code> ：跳过 LLM，直接把 raw catalog JSON 传给下游
<code>enable_problem_grounding</code>	布尔	<code>true</code>	<code>true</code> ：运行完整的问题锚定流程（4 阶段 guided loop）。 <code>false</code> ：跳过，直接将上一阶段的数据注入为消息给主 Agent


3.2 开关组合效果

<code>enable_data_inspector</code>	<code>enable_global_exploration_llm</code>	<code>enable_problem_grounding</code>	实际效果
<code>false</code>	任意	任意	两个节点都不执行，Agent 直接看原始数据
<code>true</code>	<code>true</code>	<code>true</code>	完整流水线 （默认）：LLM 生成 profile -> 问题锚定 -> 主 Agent

enable_data_inspector	enable_global_exploration_llm	enable_problem_grounding	实际效果
			收到 handoff
true	false	true	省钱模式： raw JSON -> 问题锚定处理
true	true	false	快速模式： LLM profile -> 直接给主 Agent
true	false	false	最省钱： raw JSON -> 直接给主 Agent

3.3 enable_data_inspector: false 时的流程

图的拓扑不变，但 global_data_exploration 和 problem_grounding 两个节点都直接返回 {} （空操作）：



- global_data_profile 保持 None （不构建 catalog，不调 LLM）
- inspector 保持 None （不运行 DataUnderstandingAgent，不注入 handoff）
- Agent 的 messages 里只有 system prompt + 任务问题，靠自己用工具探索数据

3.4 问题锚定参数

参数	类型	默认值	说明
<code>inject_summary_to_agent</code>	布尔	<code>true</code>	是否将 data understanding 的 handoff 摘要注入到主 Agent 的对话中
<code>max_agent_steps</code>	整数	5	问题锚定阶段（problem_grounding）最大 LLM 调用步数
<code>max_phase_retries</code>	整数	1	每个锚定阶段（grounding/fabric/contract）验证失败后的最大重试次数
<code>profile_guided_fast_path</code>	布尔	<code>true</code>	当 global profile 可用时，跳过 LLM overview 阶段；对单表/单 join 路径的任务直接用规则推导 join，不调 LLM
<code>enable_semantic_tools</code>	布尔	<code>true</code>	是否允许锚定阶段使用语义工具（search_semantic_index、lookup_knowledge 等）
<code>include_inspector_trace</code>	布尔	<code>true</code>	是否在结果中记录 inspector 的详细步骤日志
<code>context_bundle_limit</code>	整数	6	构建上下文时最多包含的候选字段数

3.5 数据采样参数 `sample_budget`

参数	类型	默认值	说明
<code>catalog_sample_rows</code>	整数	5	每个表/文件采样的行数（给 LLM 看的数据预览）
<code>catalog_top_distinct_values</code>	整数	50	每个字段展示的去重值数量，取频率最高的前 N 个。 <code>cardinality</code> 字段会报告真实的去重总数
<code>max_doc_chars</code>	整数	2000	文档类文件（knowledge.md）在 catalog 中预览的最大字符数（全文仍会传给 LLM）
<code>max_json_chars</code>	整数	4000	JSON 文件在 catalog 中预览的最大字符数

四、`run` — 运行配置

参数	类型	默认值	说明
<code>output_dir</code>	路径	<code>artifacts/runs</code>	运行产物输出目录
<code>log_dir</code>	路径	无	日志目录（仅 docker 使用）
<code>output_layout</code>	字符串	<code>run_dir</code>	产物目录结构： <code>run_dir</code> （每 run 一个子目录）或 <code>flat</code> （平铺）
<code>run_id</code>	字符串	空	运行 ID，留空自动生成

参数	类型	默认值	说明
max_workers	整数	4	并行执行任务的最大线程数
task_timeout_seconds	整数	600	单个任务超时秒数
task_ids	列表	无	要执行的任务 ID 列表。不填则执行全部

五、典型使用场景

场景 1：完整流水线（推荐，数据质量最高）

```
agent:
  enable_data_inspector: true
data_inspector:
  enable_global_exploration_llm: true
  enable_problem_grounding: true
```

场景 2：省钱模式（跳过 global profiling 的 LLM 调用）

```
data_inspector:
  enable_global_exploration_llm: false
  enable_problem_grounding: true
```

场景 3：快速模式（跳过问题锚定，LLM profile 直接给 Agent）

```
data_inspector:
  enable_global_exploration_llm: true
  enable_problem_grounding: false
```

场景 4：最省钱（两个 LLM 阶段都跳过）

```
data_inspector:
  enable_global_exploration_llm: false
  enable_problem_grounding: false
```

场景 5：完全不用 data inspector（裸 Agent）

```
agent:  
  enable_data_inspector: false
```